Análisis y Visualización de Datos

Diplomatura
Diplodatos 2026

Teoría para aplicar

Muestreo aleatorio

Cuando recogemos los datos muchas veces es imposible relevar la característica de interés de todo el grupo o universo, se examina una pequeña parte, llamada muestra.

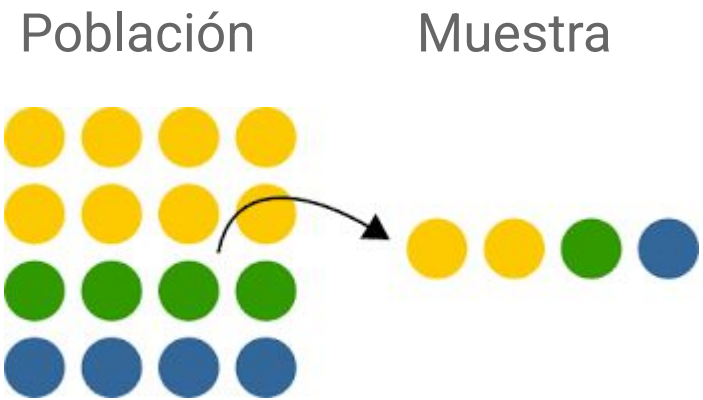

La muestra debe ser representativa de la población

Muestreo Probabillístico

Muestreo Aleatorio Simple

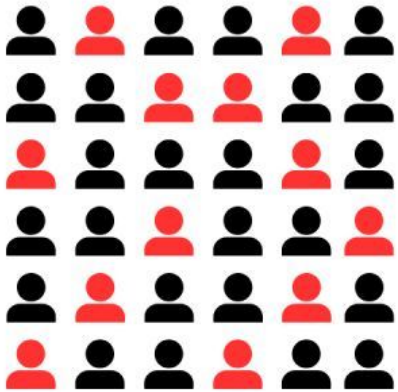

Muestreo Sistemático

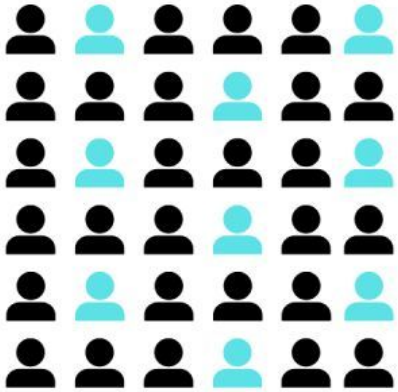

Muestreo Estratificado

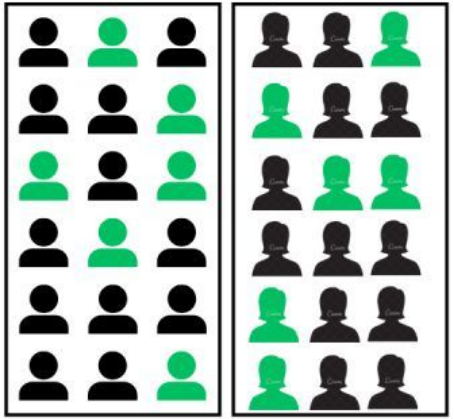

Muestreo por Conglomerados

Muestra aleatoria

Al medir una característica en una muestra, se consideran los datos $x_1, x_2, \ldots, x_n$ obtenidos como realizaciones de variables aleatorias $X_1, X_2, \ldots, X_n$

Este conjunto de variables se llama muestra aleatoria (m.a.).
Porqué?

- Si los objetos son elegidos al azar
  - Las variables son independientes
  - Las distribuciones son iguales
  - Esto es, repito el experimento muchas veces

Muestra aleatoria - Teoría

- Una sucesión de v.a. $X_1, X_2, \ldots, X_n$ se dice **muestra aleatoria (m.a.)** si son v. a. independientes e idénticamente distribuidas (i.i.d.).

- "Clones" de una misma X

Muestra aleatoria - Teoría

A partir de los clones, podemos calcular estadísticos, que también son variables aleatorias con distribución propia.

Como por ejemplo el **estadístico Media Muestral:**

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

Algunas propiedades teóricas: Muestra aleatoria

- Si $X_1, X_2, \ldots, X_n$ m.a. (v.a.i.i.d.) tal que $X_i \sim N(\mu, \sigma^2)$, entonces:

  - $X_1 + X_2 + \ldots + X_n \sim N(n\mu, n\sigma^2)$
  - $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \sim N(\mu, \sigma^2/n)$

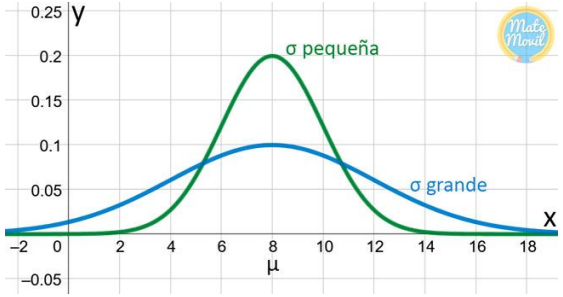

- Si $Z_1, Z_2, \ldots, Z_n$ m.a. tal que $Z_i \sim N(0,1)$, entonces:

$$V = \sum_{i=1}^{n} Z_i^2 \sim \chi_n^2$$

LGN: Ley de los Grandes Números

- Dada. $X_1, \ldots X_n$ m.a. c/u con media μ ("clones" de la misma variable con distribución cualquiera pero con esperanza $E(X_1) = \mu$, media poblacional)

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{P} \mu \qquad P\left(\left|\overline{X} - \mu\right| \leq \epsilon\right) \underset{n\to\infty}{\longrightarrow} 1$$

TCL: Teorema Central del Límite

- Sea $X_1, \ldots X_n$ m.a. c/u con media μ y varianza σ^2. ("clones" de la misma variable <u>con distribución cualquiera</u> pero con media μ y varianza σ^2)

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{\mathfrak{D}} Z \sim N(0,1))$$

$$\overline{X} \approx N(\mu, \sigma^2/n)$$

TCL: Teorema Central del Límite

- La densidad de **la v.a. media muestral** parece acampanada p/ **n grande**, **aprox. normal**, cualquiera sea la distribución en la población;

- La densidad de **la media muestral** crece en altura y decrece en dispersión si n crece.

- La media de la distribución del promedio muestral es igual a la media de la población
- La varianza de la distribución de la media muestral es menor que la varianza de la población;

TCL: Teorema Central del Límite

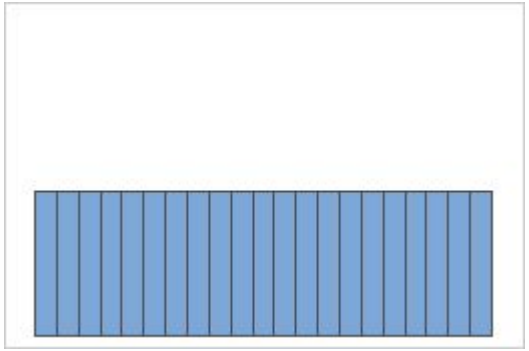

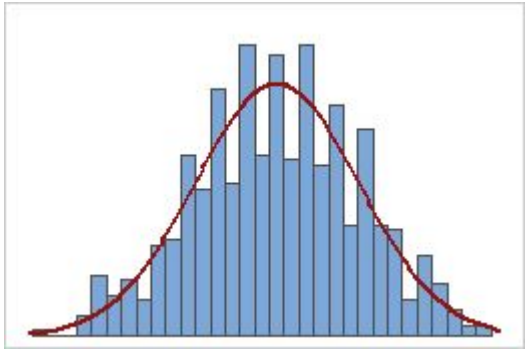

X_i ~ Uniforme

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

TCL: Teorema Central del Límite

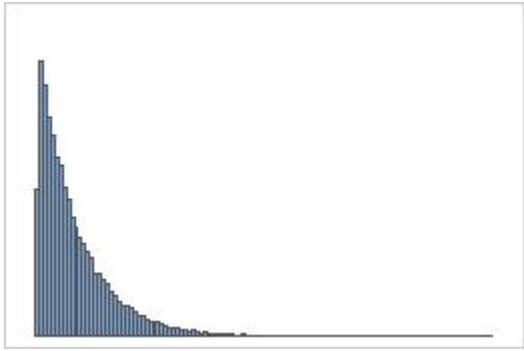

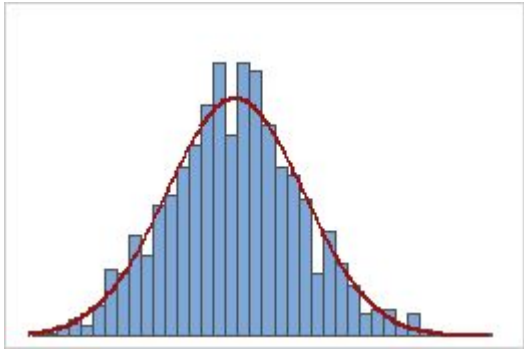

X_i ~ exponencial

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

¿Que pasa si no tengo distribuciones normales? ¿Y si tengo pocos clones?

- Existen estimadores y procedimientos no paramétricos.
- Esto es, no me baso en la forma analítica de la distribución

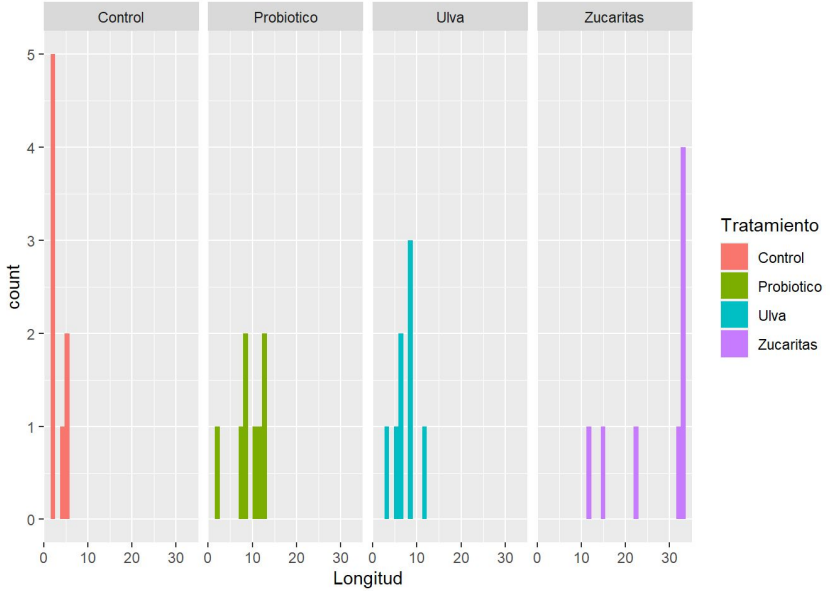

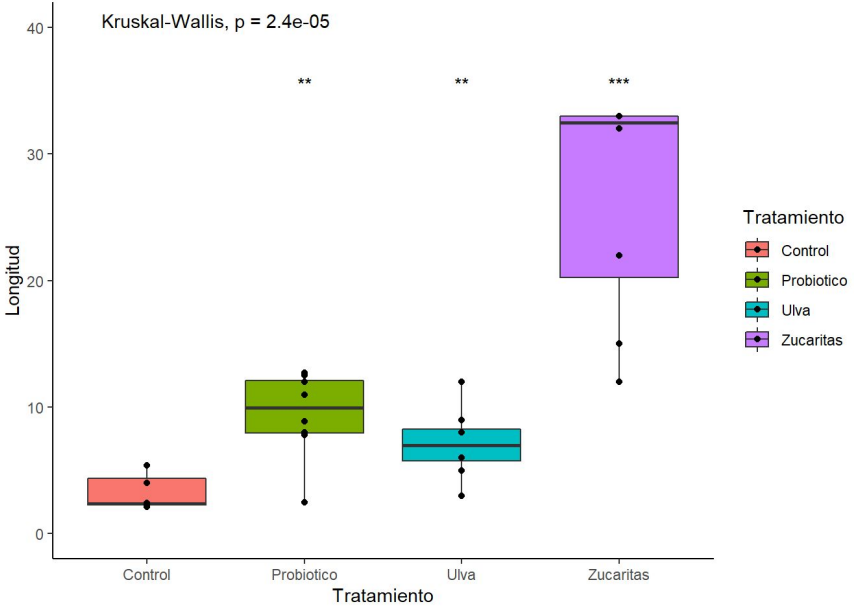

Estadística Inferencial

Inferencia Estadística

- Métodos utilizados para **tomar decisiones** o para **obtener conclusiones** sobre una población (usa modelos y parámetros generalmente).

- Estos métodos utilizan la información contenida en una muestra de la población.

- Permiten **inferir** el comportamiento de la población con un riesgo medible en términos de **probabilidad de error**.

Inferencia Estadística

Si nos ubicamos dentro de la estadística paramétrica:

- Se considera una característica de interés de la **población (Ω).**
- Se supone que la característica está modelada por una **variable aleatoria X** con distribución **"conocida"** y paramétrica $f_{\Theta}(x)=f(x,\Theta)$. (ej $\Theta=(\mu,\sigma^2)$ en Normal)
- Se considera una **muestra aleatoria (m.a.) X_1, ...X_n,** con la misma distribución (paramétrica) que X.

Inferencia Estadística

Incluye dos grandes áreas:

- estimación de parámetros (p/estadística paramétrica)
- pruebas de hipótesis

Demo con Notebook

04 Estadísticos.ipynb