Análisis y Visualización de Datos

Diplomatura
Diplodatos 2026

Estimación

Estimación de parámetros

$X_1, \ldots X_n$ m.a. de <u>modelo</u> paramétrico, parámetro μ

- **Estimación puntual** (por estadístico, estimador del parámetro).

$$\widehat{\mu} \approx \mu \qquad , \text{donde } \widehat{\mu} = \widehat{\mu}(X_1, \ldots X_n), \text{ estadístico}$$

- **Estimación por intervalo,** ($I=I(X_1, \ldots X_n)$ y $S=S(X_1, \ldots X_n)$, estadísticos)

$$\mu \in [I, S] \qquad P(I \leq \mu, \mu \leq S) \approx 1$$

Estimación puntual

Estimación puntual: Estadístico

Definición

Un estadístico es cualquier función real definida sobre una muestra aleatoria de clones.

$g(X_1, \ldots, X_{\square})$

Propiedad Clave

Resulta ser una **variable aleatoria**.

$h(X_1, \ldots, X_{\square})$

Estimación puntual: Estadístico

Podemos definir **estadísticos** para estimar un **parámetro**.

PARÁMETRO

Medida resumen del modelo-población.

Valor desconocido

ESTADÍSTICO

Medida resumen de la muestra.

Variable aleatoria

Ejemplo:

parámetro

μ

estadístico $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$

Estimación de parámetro por estadístico

Ejemplo: Sea $X_1, \ldots, X_n$ muestra aleatoria de una población con media μ

Propiedades del Estimador

La media muestral $\bar{X}$ es un:

- **Buen estimador** de μ
- **Consistente**

Justificación: Ley de Grandes Números (LGN)

Por la LGN, la media muestral converge en probabilidad al parámetro poblacional:

Esto garantiza que a medida que n crece, el error de estimación tiende a cero.

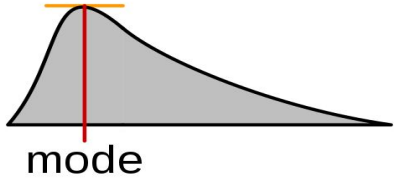

Estimadores de parámetros: Más Ejemplos

$$S^2 = \frac{\sum_i (Xi - \bar{X})^2}{n}$$

$$S^2 = \frac{\sum_{i=1}^{n} (X_j - \overline{X})^2}{n-1}$$

estimadores de $\sigma^2 = E(X-\mu)^2$

$$s = \sqrt{s^2} = \sqrt{\frac{\sum (X - \bar{X})^2}{n-1}}$$

estimador de σ

$$CA_F = \frac{\sum_{i=1}^{N} (x_i - \overline{x})^3}{N \cdot S_x^3}$$

siendo $\overline{x}$ la media y S_x la desviación típica

estimador de $E(X-\mu)^3/\sigma^3$

Estimadores: Exactitud

Objetivo: Estimar el parámetro poblacional θ

Estimador (v.a.) $$\widehat{\theta} = \widehat{\theta}(X_1, ...X_n)$$

Sesgo del Estimador $$sesgo = E(\hat{\theta}) - \theta$$

Insesgadez

Un estimador es **insesgado** si su sesgo es igual a 0.

Conceptos Clave

Sesgo → **EXACTITUD**
Varianza → **PRECISIÓN**

Ni preciso
ni exacto

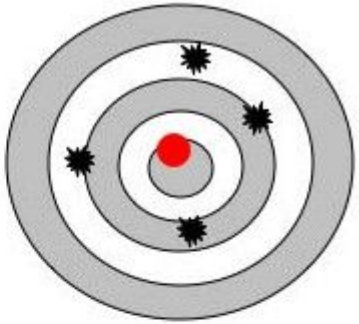

Impreciso
pero exacto

Preciso
pero inexacto

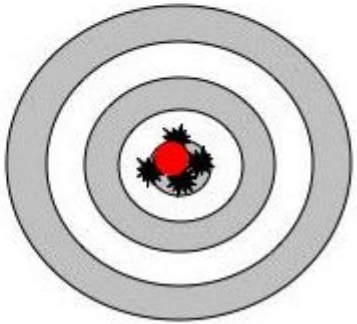

Preciso y exacto

Estimadores: Precisión (eficiencia)

Definición: Comparación de Varianza

Un estimador es **más preciso** (eficiente) que otro, si la varianza del primero es menor que la del segundo.

Ejemplo Comparativo

Sean y estimadores de θ:

$$\mathrm{Var}(\hat{\theta}_1) < \mathrm{Var}(\hat{\theta}_2)$$

Entonces, $\widehat{\theta}_1$ es más preciso que $\widehat{\theta}_2$

CONCLUSIÓN: Un estimador es más preciso cuanto menor es su varianza.

Estimadores: Sesgo y Eficiencia (precisión)

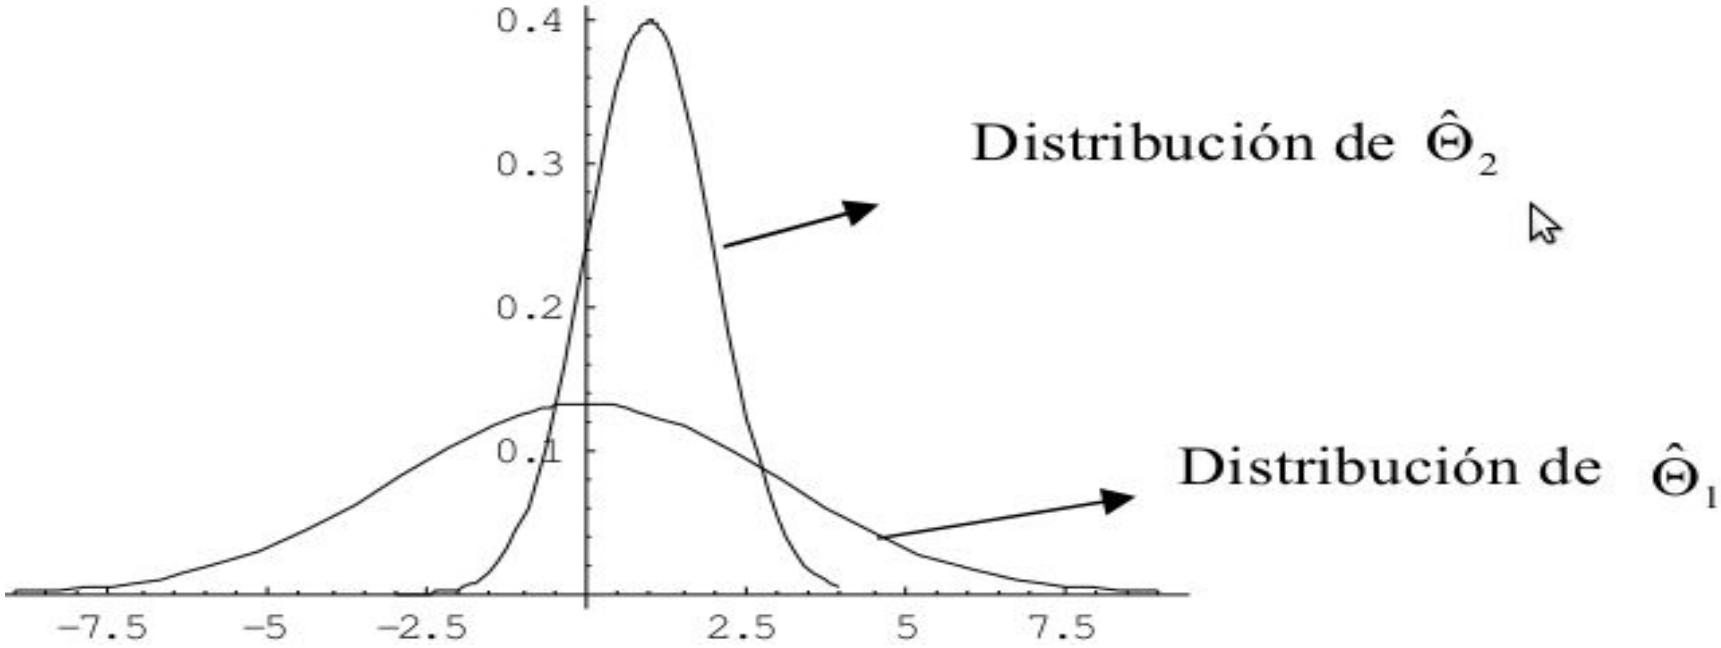

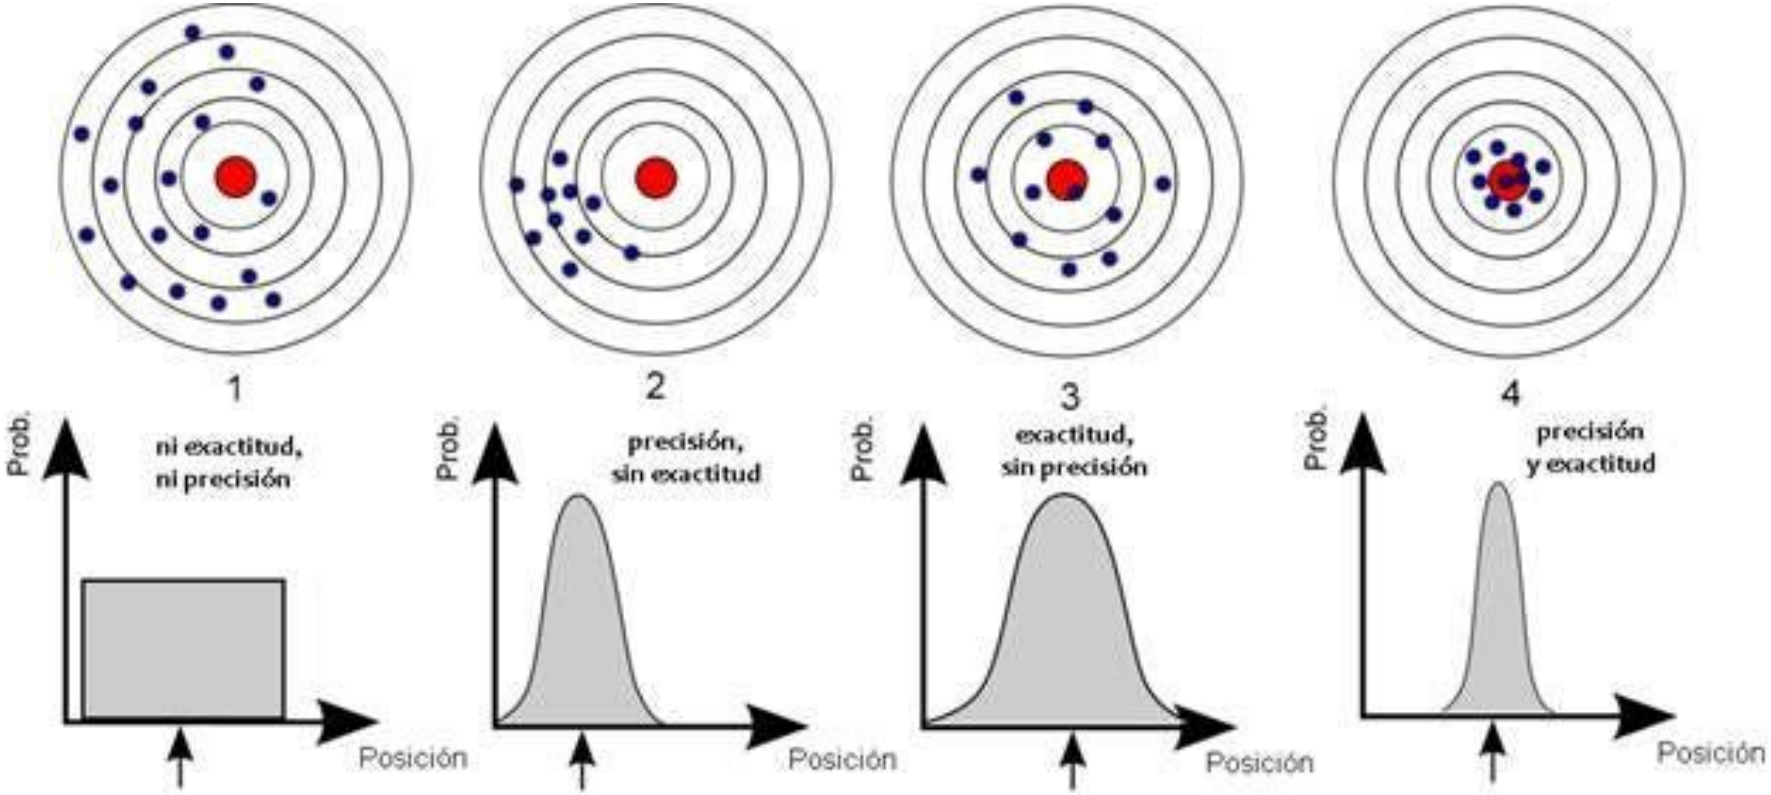
1
2
3
4
Prob.
ni exactitud,
ni precisión
Posición
Prob.
precisión,
sin exactitud
Posición
Prob.
exactitud,
sin precisión
Posición
Prob.
precisión
y exactitud
Posición

Estimador Insesgado y Eficiente (exacto y preciso)

$X_1, \ldots X_n$ m.a. de

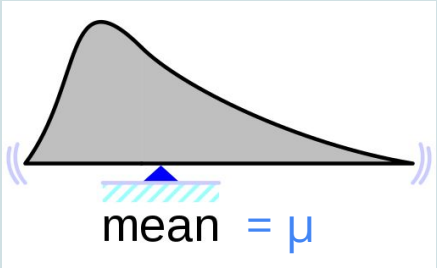

El estadístico $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ es un **estimador** insesgado y eficiente de **μ**:

$$\overline{X} \approx N(\mu, \sigma^2/n)$$

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{P} \mu$$

$$P\left(\left|\overline{X} - \mu\right| \leq \epsilon\right) \underset{n\to\infty}{\to} 1$$

LA MATRIZ DE CONFUSIÓN Y SUS MÉTRICAS

VALORES DE PREDICCIÓN

Verdaderos Positivos (VP)	Falsos Positivos (FP) ERROR tipo 1
Falsos Negativos (FN) ERROR tipo 2	Verdaderos Negativos (VN)

VALORES REALES

PRECISIÓN (Precision) ***VP/(VP+FP)***

EXACTITUD (Accuracy): ***VP+VN)/(VP+FP+FN+VN***

ESPECIFICIDAD (Specificity): ***VN/(VN+FP)***
Tasa verdaderos negativos

Tasa falsos negativos **FN/(FN+VP)**

Valor predictivo positivo: **VP/(FP+VP)**

Valor predictivo negativo: **VN/ (VN + FN)**

SENSIBILIDAD (Recall or sensitivity) ***VP/(VP+FN)***
Tasa de verdaderos positivos

Bill Ratios of Brush–Tailed Penguins (*Pygoscelis* spec.)

Distribution of bill ratios, estimated as bill length divided by bill depth.

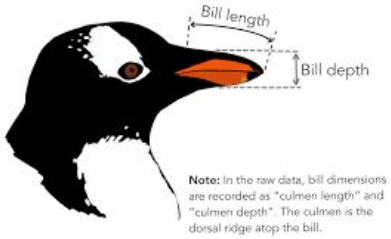

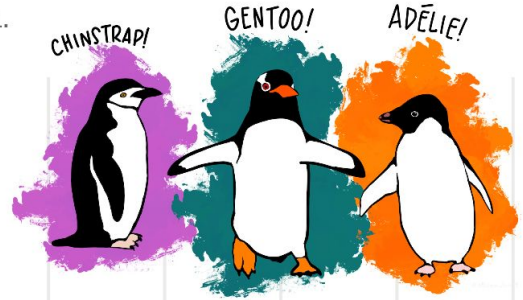

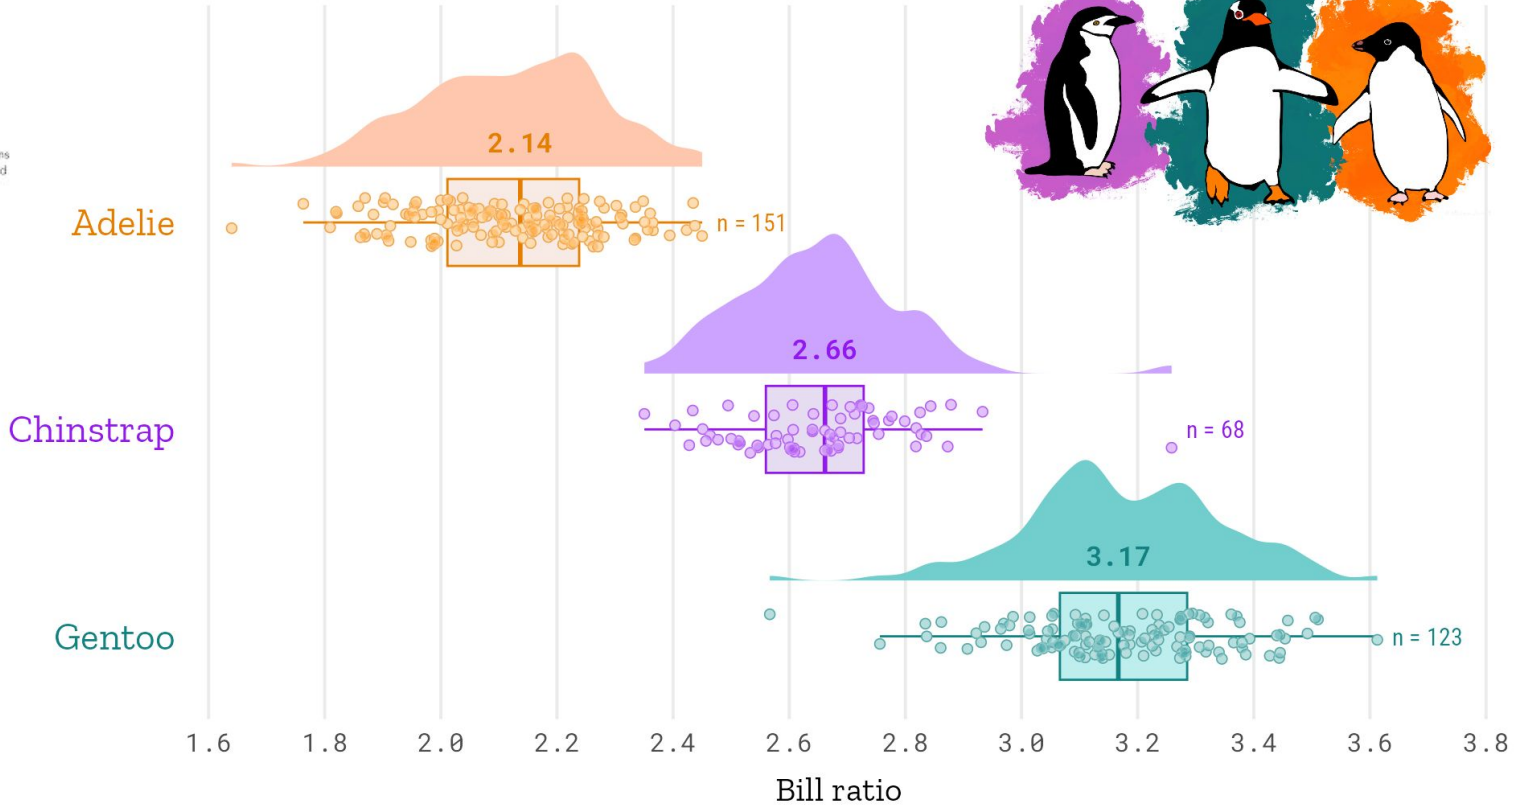

Gorman, Williams & Fraser (2014) *PLoS ONE* DOI: 10.1371/journal.pone.0090081

Visualization: Cédric Scherer • Illustration: Allison Horst

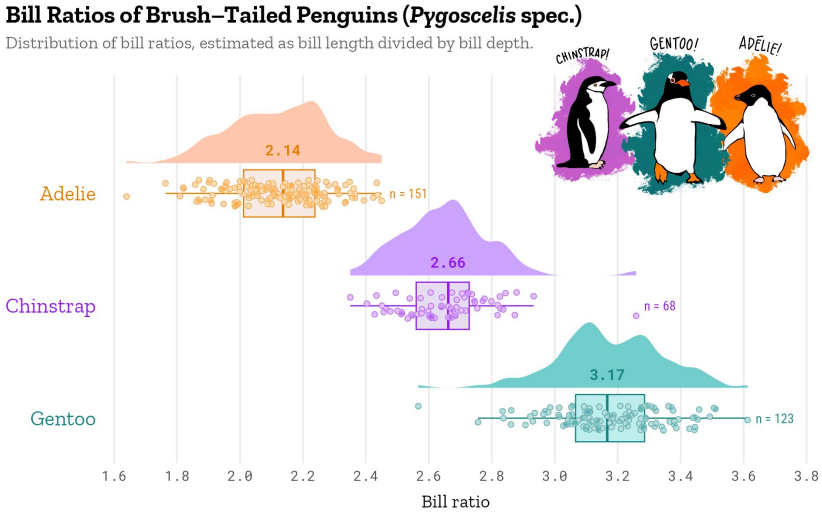

	precision	recall	f1-score	support
1	0.69	0.87	0.77	31
2	0.90	0.76	0.82	49
micro avg	0.80	0.80	0.80	80
macro avg	0.80	0.81	0.80	80
weighted avg	0.82	0.80	0.80	80

Estimación por intervalos

Intervalos de Confianza

A veces resulta más conveniente dar un **intervalo de valores posibles** del parámetro desconocido.

De manera tal que dicho intervalo contenga al verdadero parámetro con **alta probabilidad**.

Intervalos de confianza

Estimación por intervalo, ($I=I(X_1, \ldots X_n)$ y $S=S(X_1, \ldots X_n)$, estadísticos)

$$\mu \in [I, S] \qquad P(I \leq \mu, \mu \leq S) \approx 1$$

- Un intervalo de confianza es un intervalo aleatorio (con extremos aleatorios dados por estadísticos).

Intervalos de confianza

Estimación por intervalo, se quiere estimar θ

$$P(\theta \in (\hat{\theta}_1, \hat{\theta}_2)) = 1 - \alpha$$

Parámetro desconocido a estimar

es un valor real entre cero y uno dado de antemano

Intervalos de confianza: Ejemplo

Por ejemplo si pedimos un **α**=0.05 esto implica que

$$P(\hat{\theta}_1 \leq \theta \leq \hat{\theta}_2) = 0.95$$

Una probabilidad del 95% que el intervalo propuesto contenga al verdadero parámetro

Intervalos de confianza: Ejemplo

Por ejemplo si pedimos un **α**=0.05 esto implica que

$$P(\hat{\theta}_1 \leq \theta \leq \hat{\theta}_2) = 0.95$$

Una probabilidad del 95% que el intervalo propuesto contenga al verdadero parámetro

Al valor 1 - α o a (1 - α)100 % se lo llama nivel de confianza del intervalo.

Debido a su naturaleza aleatoria, es poco probable que dos muestras de una población en particular produzcan intervalos de confianza idénticos

Intervalos de Confianza

La línea negra representa el valor fijo desconocido μ. Los intervalos de confianza azules que cortan la línea negra contienen al valor μ. El intervalo de confianza rojo que está completamente por debajo de la línea horizontal no lo contiene. Un intervalo de confianza de 95% indica que 19 de c/ 20 “experimentos” (95%) producirán intervalos de confianza que contendrán al parámetro.

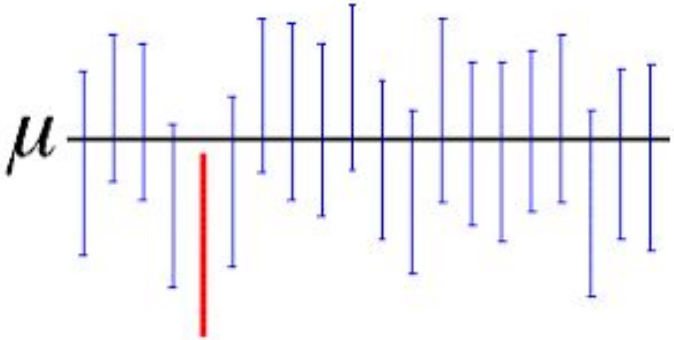

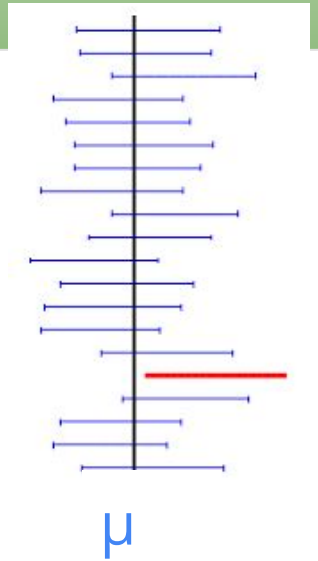

IC: Método del pivote

Se define un **estadístico (pivote)** que **depende de la m.a. y del parámetro a estimar y cuya distribución es conocida** (o aproximada a una conocida) y no depende del parámetro.

$$P(\hat{\theta}_1 \leq \theta \leq \hat{\theta}_2) = 0.95$$

IC: Método del pivote

- Se define un **estadístico (pivote)** que **depende de la m.a. y del parámetro a estimar y cuya distribución es conocida** (o aproximada a una conocida) y no depende del parámetro.

- Al conocer la distribución del **estadístico pivote** se puede establecer el intervalo donde el valor del pivote tiene probabilidad **1 - α** .

IC: Método del pivote

Se define un **estadístico (pivote)** que **depende de la m.a. y del parámetro a estimar y cuya distribución es conocida** (o aproximada a una conocida) y no depende del parámetro.

Se define el intervalo donde los valores del **estadístico pivote** tienen probabilidad **1 - α**.

Luego se despeja el **parámetro**, condicionado por los extremo del intervalo con probabilidad (o **nivel de confianza**) **1 - α .**

Veamos un ejemplo sencillo para llevarlo a la práctica...

Método del Pivote: Ejemplo

- Sea $X_1, X_2, \ldots, X_n$ una m.a. de una v.a. $X \sim N(\mu, \sigma^2)$, σ^2 conocido.
- Se quiere construir un IC para de nivel $(1 - \alpha)$,

Notemos que $\bar{X} - \mu \sim N(0, \sigma^2/n)$, su distribución ya no depende de μ

Y luego $\dfrac{\overline{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$, distribución conocida y no depende de ningún parámetro

Pivote

Método del Pivote: Ejemplo

- Sea $X_1, X_2, \ldots, X_n$ una m.a. de una v.a. $X \sim N(\mu, \sigma^2)$, σ^2 conocido.
- Se quiere construir un IC para de nivel $(1 - \alpha)$,

$$\frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1),$$

$$P\left(-z_{\alpha/2} \leq \frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = (1 - \alpha)$$

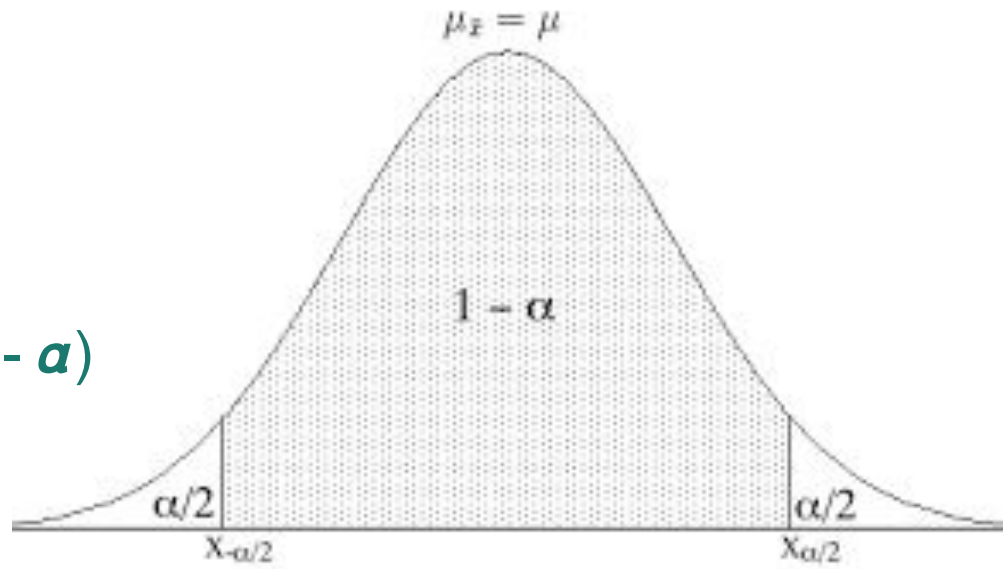

Método del Pivote: Ejemplo

- Sea $X_1, X_2, \ldots, X_n$ una m.a. de una v.a. $X \sim N(\mu, \sigma^2)$, σ^2 conocido.
- Se quiere construir un IC para de nivel $(1 - \alpha)$,

$$\frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1), \qquad P\left(-z_{\alpha/2} \leq \frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = (1 - \alpha)$$

Pivote

$$P\left(\underbrace{\boxed{\overline{X} - \frac{\sigma z_{\alpha/2}}{\sqrt{n}}}}_{I} \leq \mu \leq \underbrace{\boxed{\overline{X} + \frac{\sigma z_{\alpha/2}}{\sqrt{n}}}}_{S}\right) = (1 - \alpha)$$

$$[I, S] \text{ es IC de nivel } 1 - \alpha \text{ para } \mu$$

TCL- Intervalo de confianza asintótico n grande, no se cual es la distribución

Sea $X_1, \ldots X_n$ m.a. c/u con media μ y varianza σ^2.

$$\frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \approx N(0,1)$$

$$P\left(-z_{\alpha/2} \leq \frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) \approx 1 - \alpha$$

$$P\left(\underbrace{\boxed{\overline{X} - \frac{\sigma z_{\alpha/2}}{\sqrt{n}}}}_{I} \leq \mu \leq \underbrace{\boxed{\overline{X} + \frac{\sigma z_{\alpha/2}}{\sqrt{n}}}}_{S}\right) \approx 1 - \alpha$$

$[I, S]$ es IC de nivel asintótico $1-\alpha$ para μ

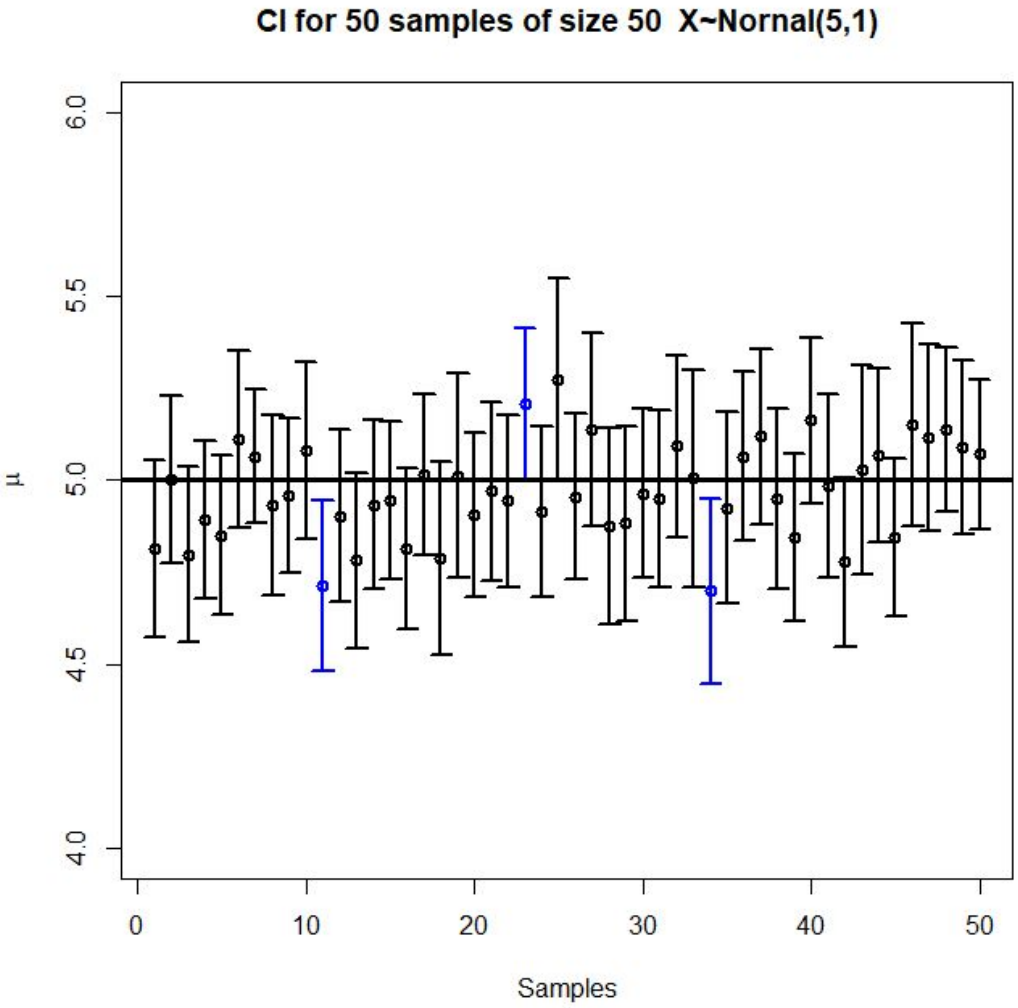
CI for 50 samples of size 50 X~Nornal(5,1)
6.0
5.5
5.0
4.5
4.0
μ
0
10
20
30
40
50
Samples

IC cuando clones son normales pero no se la varianza, t de Student

$$T = \frac{\overline{X} - \mu}{S/\sqrt{n}}$$

$$S^2 = \frac{1}{n-1}\sum_{1=1}^{n}\left(X_i - \overline{X}\right)^2$$

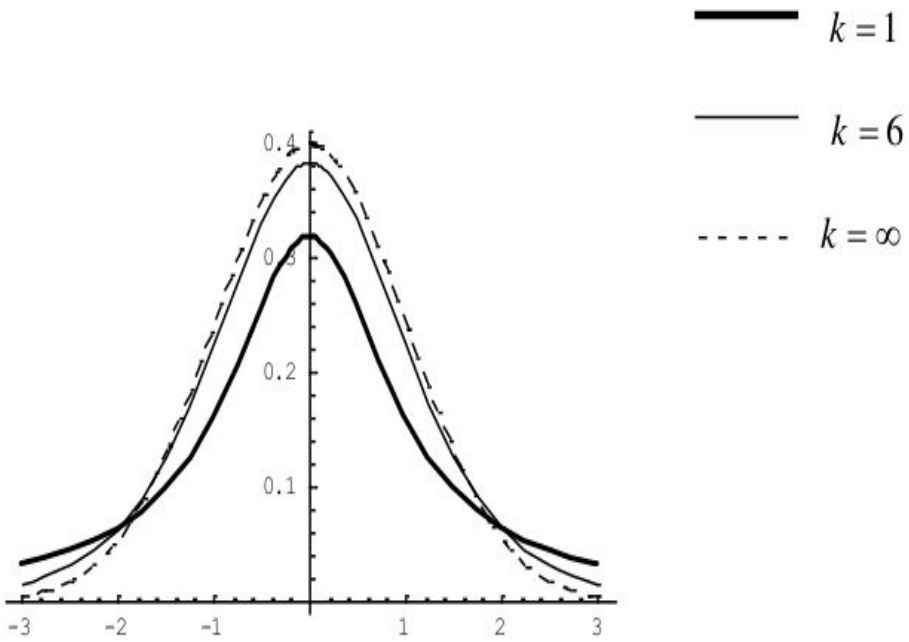

IC cuando clones son normales pero no se la varianza, t de Student n-1 gl

$$P\left(\overline{X} - t\frac{S}{\sqrt{n}} \le \mu \le \overline{X} + t\frac{S}{\sqrt{n}}\right) = 1\text{-}\alpha$$

Evidentemente, si definimos

$$\begin{cases} \hat{\Theta}_1 = \overline{X} - t\dfrac{S}{\sqrt{n}} \\ \hat{\Theta}_2 = \overline{X} + t\dfrac{S}{\sqrt{n}} \end{cases}$$

, hemos construido dos estadísticos $\hat{\Theta}_1$ y $\hat{\Theta}_2$ tales que $P\left(\hat{\Theta}_1 \le \mu \le \hat{\Theta}_2\right) = 1\text{-}\alpha$,

veamos quien es el número t que verifica la ecuación, es decir (ver figura):

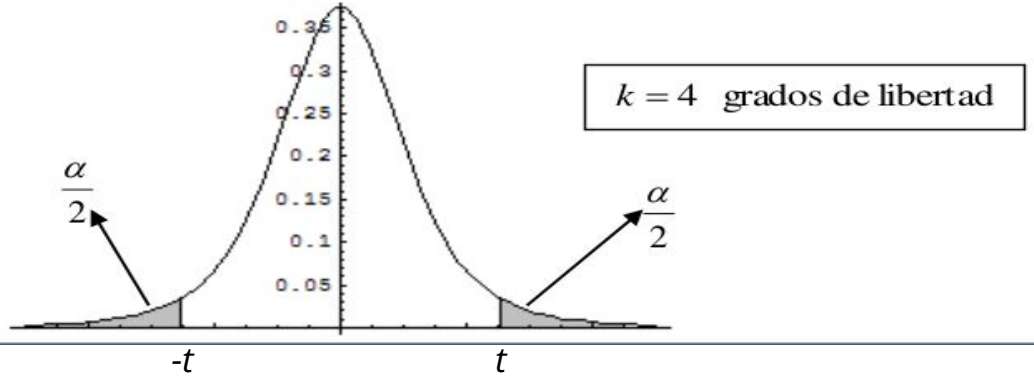

IC para μ de una normal con σ desconocido

Si $(X_1, X_2, \ldots, X_n)$ una muestra aleatoria de tamaño n de una v.a. X donde $X \sim N(\mu, \sigma^2)$, σ^2 desconocido, un intervalo de confianza para μ de nivel $1-\alpha$ es

$$\left[\overline{X} - t_{\frac{\alpha}{2}} \frac{S}{\sqrt{n}}, \overline{X} + t_{\frac{\alpha}{2}} \frac{S}{\sqrt{n}}\right] \qquad (8.2)$$

IC para dif de medias μ_1-μ_2

<u>Muestras apareadas</u>:

$X_1, X_2, \ldots, X_n$ m.a. de una v.a. $X \sim N(\boldsymbol{\mu}_1, \boldsymbol{\sigma}_1^2)$

$Y_1, Y_2, \ldots, Y_n$ m.a. de una v.a. $Y \sim N(\boldsymbol{\mu}_2, \boldsymbol{\sigma}_2^2)$

$(X_1,Y_1), (X_2,Y_2) \ldots, (X_n,Y_n)$ una m.a. de normal bivariada $N((\boldsymbol{\mu}_1,\boldsymbol{\mu}_1),(\boldsymbol{\sigma}_1^2, \boldsymbol{\sigma}_2^2,\rho))$

$Z_i=X_i-Y_i$ $Z_1, Z_2, \ldots, Z_n$ m.a. de una v.a. $N(\boldsymbol{\mu}_1-\boldsymbol{\mu}_2, \boldsymbol{\sigma}_1^2+ \boldsymbol{\sigma}_2^2-2\rho*(\boldsymbol{\sigma}_1 \boldsymbol{\sigma}_2))$

como el caso de Z=BRUTO-NETO.

Z(i)= BRUTO(persona i)-NETO(persona i) p/ c/ persona i.

Casos normales

- Si conozco la varianza, tengo un pivote Z
  -
- Si no conozco la varianza tengo un pivote t
  -
- si n es grande?

Casos

Poblaciones Normales		Poblaciones No Normales	
σ^2 conocida		σ^2 conocida	
n Cualquiera	Distribución Normal $\bar{x} \pm z\frac{\sigma}{\sqrt{n}}$	$n \geq 30$	Distribución Normal (Por TCL) $\bar{x} \pm z\frac{\sigma}{\sqrt{n}}$
		$n < 30$	
σ^2 desconocida		σ^2 desconocida	
$n < 30$	"t" de Student $\bar{x} \pm t_{n-1}\frac{\hat{s}}{\sqrt{n}}$	$n < 30$	
$n \geq 30$	Distribución Normal (Por TCL) $\bar{x} \pm z\frac{\hat{s}}{\sqrt{n}}$	$n \geq 30$	Distribución Normal (Por TCL) $\bar{x} \pm z\frac{\hat{s}}{\sqrt{n}}$

IC para dif de medias μ_1-μ_2

Supongamos tener muestras independientes

- $X_1, X_2, \ldots, X_{n1}$ una m.a. de una v.a. $X \sim N(\boldsymbol{\mu}_1, \boldsymbol{\sigma}^2)$
- $Y_1, Y_2, \ldots, Y_{n2}$ con distribución $N(\boldsymbol{\mu}_2, \boldsymbol{\sigma}^2)$,
- Igual varianza distinto tamaño de muestra

IC para dif de medias μ_1-μ_2

Entonces el pivote tiene distribución t de student

$$T = \frac{\left(\overline{X} - \overline{Y}\right) - \left(\mu_1 - \mu_2\right)}{S\sqrt{\left(n_1 + n_2\right)/n_1 n_2}} \sim t_{n_1+n_2-2}$$

$$Var(\overline{X} - \overline{Y}) = \frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_2} \qquad S^2 = \frac{\sum_{i=1}^{n_1}\left(X_i - \overline{X}\right)^2 + \sum_{i=1}^{n_2}\left(Y_i - \overline{Y}\right)^2}{n_1 + n_2 - 2}$$

$$(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2}\sqrt{s_p^2\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}$$

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

$$df = n_1 + n_2 - 2.$$

IC para dif de medias μ_1-μ_2 t de Welch

Supongamos tener muestras no apareadas

$X_1, X_2, \ldots, X_{n1}$ una m.a. de una v.a. $X \sim N(\boldsymbol{\mu}_1, \boldsymbol{\sigma}_1^2)$ independiente de otra muestra

$Y_1, Y_2, \ldots, Y_{n2}$ con distribución $N(\boldsymbol{\mu}_2, \boldsymbol{\sigma}_2^2)$, con **distinta varianza**

y distinto tamaño de muestra

IC para dif de medias μ_1-μ_2 t de Welch

$X_1, X_2, \ldots, X_{n1}$ una m.a. de una v.a. $X \sim N(\mu_1, \sigma_1^2)$ indep de
$Y_1, Y_2, \ldots, Y_{n2}$ una m.a. de una v.a. $Y \sim N(\mu_2, \sigma_2^2)$, distinto tam. (no apareadas)

si Varianzas no son iguales y la cantidad de muestras no es igual, el pivote:

$$t = \frac{\Delta \overline{X}}{s_{\Delta \bar{X}}} = \frac{\overline{X}_1 - \overline{X}_2}{\sqrt{s^2_{\bar{X}_1} + s^2_{\bar{X}_2}}}, \qquad s_{\bar{X}_i} = \frac{s_i}{\sqrt{N_i}},$$

$$\nu \approx \frac{\left(\frac{s_1^2}{N_1} + \frac{s_2^2}{N_2}\right)^2}{\frac{s_1^4}{N_1^2 \nu_1} + \frac{s_2^4}{N_2^2 \nu_2}}.$$

Grados de libertad

IC para dif de medias μ_1-μ_2

$$CI(\mu_1 - \mu_2) : \overline{X}_1 - \overline{X}_2 \pm \sqrt{s^2_{\bar{X}_1} + s^2_{\bar{X}_2}} \times t_{\nu,1-\alpha/2}$$

$$\nu \approx \frac{\left(\frac{s_1^2}{N_1} + \frac{s_2^2}{N_2}\right)^2}{\frac{s_1^4}{N_1^2 \nu_1} + \frac{s_2^4}{N_2^2 \nu_2}}.$$

Grados de libertad de la distribución t

IC para σ^2 de una normal

Supongamos que se quiere hallar un intervalo de confianza para σ^2 de una distribución normal.
Sea X_1 , X_2 ,..., X_{1n} una muestra aleatoria de una v.a. X, donde X~N(μ, σ^2).

$$S^2 = \frac{1}{n-1}\sum_{1=1}^{n}\left(X_i - \bar{X}\right)^2$$

$$\frac{(n-1)S^2}{\sigma^2}$$

Estimador

Pivote con distribución $\chi^2_{(n-1)}$ **conocida**

IC para σ^2

- Un fabricante de detergente líquido está interesado en la **uniformidad** de la máquina utilizada para llenar las botellas.
- De manera específica, es deseable que la desviación estándar **σ** del proceso de llenado sea menor que 0.15 onzas de líquido
- Supongamos que la distribución del volumen de llenado es aproximadamente normal.
- Al tomar una muestra aleatoria de 20 botellas, se obtiene una varianza muestral $S^2 = 0.0153$.
- Hallar un intervalo de confianza de nivel 0.95 para la verdadera varianza σ^2 y con este un IC para **el verdadero desvío σ** del volumen de llenado.

IC para σ

Solución:

La v.a. de interés es X: " volumen de llenado de una botella"

Se asume que $X \sim N(\mu, \sigma^2)$ con σ desconocido.

Estamos en las condiciones para aplicar (8.8)

Tenemos que $1-\alpha = 0.95 \rightarrow \alpha = 0.05 \rightarrow \chi^2_{1-\frac{\alpha}{2},n-1} = \chi^2_{0.975,19} = 8.91$ y $\chi^2_{\frac{\alpha}{2},n-1} = \chi^2_{0.025,19} = 32.85$

Además $S^2 = 0.0153$ $\Rightarrow S$=0,1237

Por lo tanto el intervalo es

$$\left(\frac{(n-1)S^2}{\chi^2_{\frac{\alpha}{2},n-1}}; \frac{(n-1)S^2}{\chi^2_{1-\frac{\alpha}{2},n-1}} \right) = \left(\frac{(20-1)\times 0.0153}{32.85}; \frac{(20-1)\times 0.0153}{8.91} \right) = (0.00884;\ 0.0326)$$

Y un intervalo para σ es $\left(\sqrt{0.00884};\ \sqrt{0.0326}\right) = (0.09;\ 0.1805)$